Durée : 1h30 – Sans document

Programmation Multicœur et GPU

Barème indicatif : 2 - 1 - 1 - 5 - 2 - 3 - 2 - 1 - 3

MPI (2 pts)

Question 1 Quelles sont les différences entre les fonctions MPI_Isend() et MPI_Send()? Décrire une situation où l'emploi MPI_Isend() est particulièrement avantageux.

Question bonus: donner un second cas d'utilisation sans rapport avec le premier.

Optimisation de code séquentiel (2 pts)

Le code suivant place dans C la somme de A et de la transposée de B.

```
int A[DIM][DIM];
int B[DIM][DIM];
int C[DIM][DIM];
...
for (int i = 0; i < DIM; i++)
    for (int j = 0; j < DIM; j++)
        C[i][j] = A[i][j] + B[j][i];</pre>
```

On suppose que le cœur dispose d'un cache de 128 ko dont les lignes font 64 octets (il y a donc 2048 entrées de 64 octets). Un entier est codé sur 4 octets, une ligne de cache contient donc 16 entiers. Ce cache est géré par la politique LRU (évincement de la ligne de cache la moins récemment utilisée). On s'intéresse au nombre de défauts de cache provoqués par l'exécution de cet algorithme à froid (aucune donnée n'est présente dans le cache). On note ce nombre Défauts(DIM) pour des tableaux DIM \times DIM.

Question 2 Donner une estimation de Défauts(128) et Défauts(4096). Justifier soigneusement ¹. Question bonus : Quelle est la valeur la plus grande de DIM pour laquelle aucune donnée n'est chargée deux fois dans le cache?

Question 3 Quelle technique algorithmique mettre en œuvre pour optimiser ce code? On ne demande pas d'écrire le code.

Parallélisation du problème des n-dames via OpenMP (10 pts)

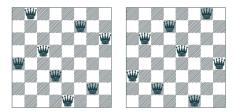


FIGURE 1 – Deux solutions au problème des 8-dames

Notre objectif est de paralléliser un programme, fort naïf, comptant le nombre de configurations de DIM dames sur un échiquier DIM × DIM sans qu'aucune d'elles ne se menacent. À titre d'illustration, la Figure 1 montre deux façons de poser 8 dames sur un échiquier de façon à ce que chaque dame soit seule à la fois sur sa rangée, sur sa colonne et sur sa diagonale. Le programme à paralléliser est présenté en Figure 2.

¹. Une matrice carrée de dimensions 128 pèse 64 ko et occupe donc 1k entrées; une matrice carrée de dimensions 4096 pèse 64Mo et occupe 1M entrées.

```
1 #define DIM 16
3 typedef bool echiquier[DIM][DIM];
5 static bool ok (int rangee, int colonne, echiquier e)
  void
11 ndames (int rangee, echiquier e, int *cpt)
     for (int colonne = 0; colonne < DIM; colonne++)</pre>
13
       if (ok (rangee, colonne, e))
                                                 // la case n'est pas menacee
15
          if (rangee == DIM - 1)
                                                  // derniere rangee
            (*cpt)++;
          else
19
            e[rangee][colonne] = true;
ndames (rangee + 1, e, cpt);
e[rangee][colonne] = false;
                                                  // placer une dame
                                                  // retirer la dame
23
       }
<sub>25</sub> }
27 int
  main ()
  {
29
     echiquier e;
     int cpt = 0;
31
     memset (e, 0, sizeof(echiquier));
                                                    // echiquier vide
33
    ndames (0, e, &cpt);
printf ("%d\n",cpt);
35
    return EXIT_SUCCESS;
```

Ce programme repose sur l'algorithme du parcours en profondeur d'abord. On part d'un échiquier vide (ligne 33) puis on appelle la fonction ndames(). Celle-ci essaye de placer les dames rangée après rangée : lors d'un appel ndames(rangee,e,cpt) on explore en largeur (ligne 13) toutes les colonnes de la rangée rangee pour tester si l'on peut y disposer une dame et, le cas échéant, on y pose une dame (ligne 20) pour lancer en profondeur le calcul sur la rangée suivante (ligne 21). Au retour de l'appel récursif on nettoie la case (ligne 22) avant de passer à la colonne suivante. Le nombre de configurations découvertes est incrémenté lorsqu'on arrive à placer une dame sur la dernière rangée (ligne 17).

FIGURE 2 – Code à paralléliser

Le code donné en Figure 2 est, par essence, similaire à celui du voyageur de commerce étudié lors de nos TP. Nous allons donc appliquer les mêmes techniques de parallélisation : parallélisation du seul premier niveau de récursivité puis parallélisation imbriquée via l'utilisation d'équipes de threads puis de tâches parallèles. On portera une attention toute particulière aux variables partagées, on les traitera au moyen des techniques vues en cours (duplication des données, mutex, instruction atomique, réduction).

Question 4 Écrire une fonction ndames_par_1(int *cpt) qui parallélise à l'aide de directives OpenMP le traitement de la première rangée. On aura intérêt à réutiliser astucieusement la fonction ndames() sans la modifier.

Note : l'étudiant sûr de lui - i.e. maitrisant la parallélisation du voyageur de commerce - pourra répondre directement à la Question 5 qui généralise cette question.

Exemple de programme utilisant ndames_par_1():

```
int
main ()
{
  int cpt = 0;
  ndames_par_1 (&cpt);
  printf ("%d\n", cpt);

  return EXIT_SUCCESS;
}
```

Question 5 Écrire une fonction ndames_par_prof (int prof, int rangee, echiquier e, int *cpt) qui parallélise le calcul jusqu'à la profondeur de récursivité prof en créant récursivement des équipes de threads imbriquées et en distribuant le travail à l'aide de la directive OpenMP for (il ne s'agit pas d'utiliser la clause collapse). On pourra :

- supposer que prof < DIM-1;</p>
- utiliser memcpy(dest,src,sizeof(echiquier)) pour recopier le contenu d'un échiquier;
- réutiliser astucieusement la fonction ndames () sans la modifier.

Exemple de programme utilisant ndames_par_prof():

Question 6 Écrire une fonction ndames_par_task (int prof, int rangee, echiquier e, int *cpt) qui parallélise le calcul à l'aide de tâches OpenMP imbriquées jusqu'à la profondeur de récursivité prof. Donner le programme principal contenant la création des threads et le lancement du calcul.

OpenCL (6 pts)

 $\label{eq:Question 7} \textbf{ Dans certains noyaux OpenCL}, il est fait appel à la primitive : \\ \texttt{barrier(CLK_LOCAL_MEM_FENCE)}$

Que fait cette instruction? Quelle est sa portée (i.e. quels sont les work items, appelés aussi threads, impliqués)? Indiquez, en donnant un exemple, dans quelles situations il est impératif d'y faire appel.

On s'intéresse à un noyau qui calcule, pour chaque ligne d'une matrice, la somme des éléments de la ligne. Le résultat est donc un vecteur, dont la $i^{\text{ème}}$ composante contient la somme des éléments de la ligne i.

La matrice est de dimension [LINES][COLS], et le vecteur de dimension LINES.

Voici un noyau OpenCL qui tente d'implémenter ce calcul. Il est exécuté par $TILE \times LINES$ work items, regroupés en workgroups de taille $TILE \times 1$. Autrement dit, un workgroup de TILE threads s'occupe de chaque ligne de la matrice.

Question 8 Il manque une instruction dans le noyau pour que celui-ci soit correct. Expliquez laquelle et indiquer à quel endroit il faut la placer.

Question 9 Expliquez en quoi la seconde partie du code (à partir de if (x == 0)) est assez maladroite. Donnez une version plus efficace de cette portion de code.